LECTURE 7 — OPEN BOOK

Guide ตอบข้อสอบจากผลที่โจทย์ให้มา

วิธีใช้

ดูว่าโจทย์ให้อะไรมา แล้วเปิดหัวข้อตามตารางข้างล่าง แต่ละหัวข้อมีสี่ส่วน คือ ดูอะไร เกณฑ์ตัดสิน แม่แบบคำตอบ และตัวอย่างคำตอบ ในแม่แบบ ส่วนที่ ***ยืดเส้นใต้*** คือส่วนที่เติมด้วยค่าจากโจทย์

คำตอบที่ครบมีสามส่วนเสมอ คือ สิ่งที่เห็นในผล (อ้างตัวเลข) ข้อสรุป และสิ่งที่ทำต่อ

โจทย์ให้มา	มักถามว่า	เปิดหัวข้อ
กราฟข้อมูลตามเวลา	ต้องแปลงหรือ differencing หรือไม่	A
กราฟ Log Likelihood กับ λ	ควรแปลงแบบใด	B
กราฟ ACF กราฟเดียว หรือ ACF ก่อนและหลัง diff	stationary หรือไม่ d เท่าใด	C
ผล Augmented Dickey-Fuller Test	stationary หรือไม่	D
กราฟ ACF คู่กับ PACF	p และ q เท่าใด โมเดลใด	E
ตารางตัวเลข 4×4 (table1, table2)	โมเดลใดดีที่สุด	F
ผลที่มี Coefficients, s.e., sigma^2	เขียนสมการ สัมประสิทธิ์ใดมีนัยสำคัญ หาค่าที่ขาด	G
ค่า ACF หรือ autocovariance เป็นตัวเลข	ประมาณ φ ด้วย Yule-Walker	H
กราฟ residual, QQ plot, Shapiro, Ljung-Box	โมเดลผ่านหรือไม่	I
ผลหลายอย่างรวมกัน	โมเดลนี้ดีหรือไม่ ถ้าไม่ดีทำอย่างไร	J
ค่า θ หรือ α	แปลงระหว่าง ARIMA กับ exponential smoothing หรือให้พิสูจน์	K
ไม่ให้ผล ถามให้อธิบาย	ทำไม อย่างไร ต่างกันอย่างไร	L
ไม่แน่ใจสัญลักษณ์หรือทิศของ p-value		N

A. โจทย์ให้กราฟข้อมูลตามเวลา

ดูอะไร

1. ระดับของข้อมูล: แกว่งรอบค่าเดิม หรือเลื่อนขึ้นลงตามเวลา
2. ความกว้างของการแกว่ง: เท่ากันตลอด หรือโตขึ้นตามเวลา ให้อ่านค่าต่ำสุดและสูงสุดช่วงต้นกับช่วงปลายจากแกนตั้ง
3. รูปแบบที่ซ้ำเป็นรอบ: มีหรือไม่

เกณฑ์ตัดสิน

เห็น	สรุป	ทำต่อ
ระดับคงที่ ความกว้างคงที่	stationary	ไม่แปลง ไม่ differencing ใช้ d = 0
ระดับเลื่อนขึ้นหรือลง	มี trend ไม่ stationary	ทำ differencing
ความกว้างโตขึ้นเมื่อระดับสูงขึ้น	ความแปรปรวนไม่คงที่	แปลงข้อมูลก่อน เช่น log แล้วจึง differencing
ขึ้นลงซ้ำทุกช่วงเท่า ๆ กัน	มี seasonality	ระบุในคำตอบ

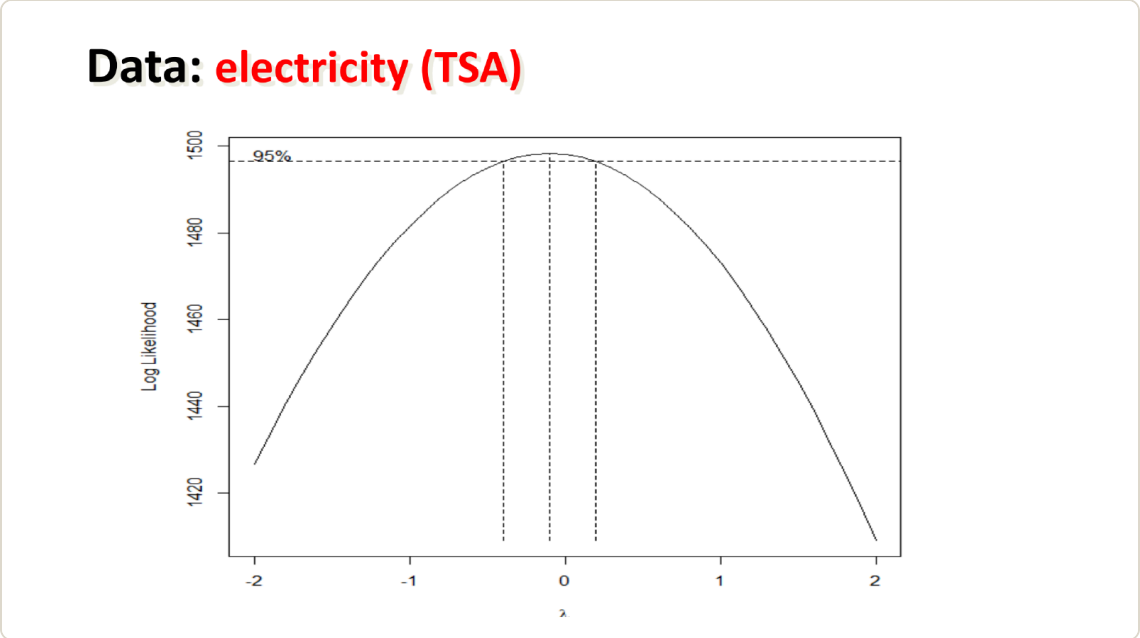
แม่แบบคำตอบ

กราฟแสดงว่าข้อมูล *มี trend ขาขึ้น / แกว่งรอบระดับเดิม* และความกว้างของการแกว่ง *โตขึ้นจาก ... เป็น ... / คงที่* ข้อมูลจึง *ไม่เป็น / เป็น* stationary ขั้นต่อไปคือ *แปลงด้วย log แล้วทำ differencing / ไม่ต้องทำอะไร*

> **ตัวอย่างคำตอบ:** electricity: ข้อมูลเพิ่มจากประมาณ 150,000 เป็น 400,000 จึงมี trend ขาขึ้น ความกว้างของการแกว่งโตจากราว 40,000 เป็นราว 110,000 ความแปรปรวนจึงไม่คงที่ ข้อมูลไม่เป็น stationary ต้องแปลงข้อมูลก่อน แล้วจึงทำ differencing

> **ตัวอย่างคำตอบ:** times.txt: ข้อมูลแกว่งรอบศูนย์ระหว่างประมาณ −6 ถึง 6 ตลอด 150 ช่วงเวลา ไม่มี trend และความกว้างคงที่ จึงไม่ต้องแปลงและไม่ต้อง differencing ใช้ d = 0

B. โจทย์ให้กราฟ Log Likelihood กับ λ (ผล BoxCox.ar)



Slide 7 หน้า 10

เส้นโค้งสูงสุดที่ λ ประมาณ −0.1 และช่วง 95% อยู่ระหว่างประมาณ −0.4 ถึง 0.2 ค่า 0 อยู่ในช่วงนี้ ส่วนค่า 1 อยู่นอกช่วง ข้อมูลจึงสนับสนุนการแปลง log และไม่สนับสนุนการคงข้อมูลไว้ตามเดิม

ดูอะไร

1. ค่า λ บนแกนนอนที่เส้นโค้งสูงที่สุด
2. ขอบซ้ายและขอบขวาของช่วง 95% บนแกนนอน
3. ช่วงนั้นครอบคลุมค่าใดใน 0, 0.5, 1

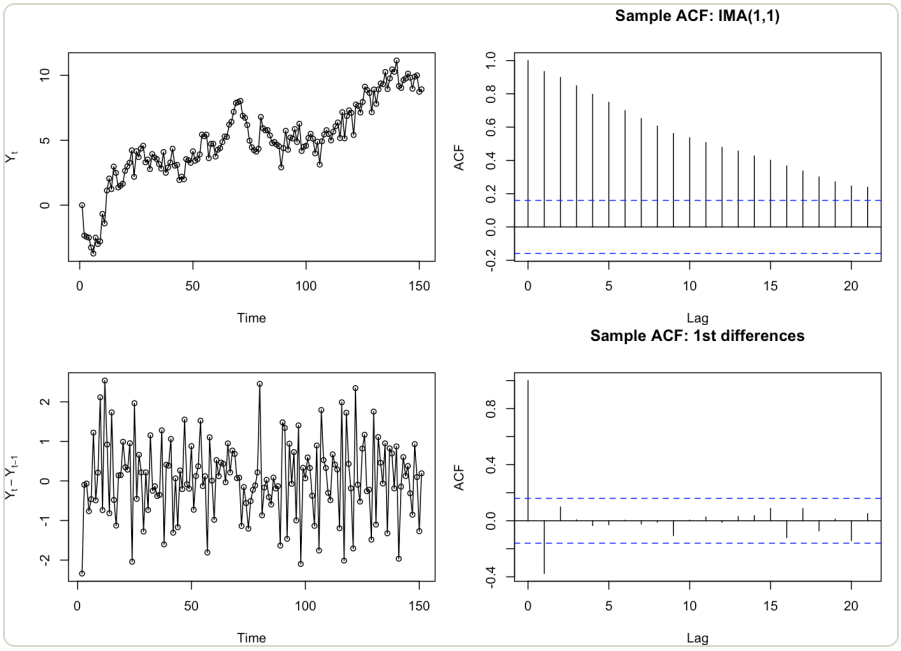
เกณฑ์ตัดสิน

ช่วง 95% ครอบคลุม	การแปลง
0	log
0.5	รากที่สอง
1	ไม่ต้องแปลง
−1	ส่วนกลับ

> **แม่แบบคำตอบ**
> ค่า λ ที่ให้ log-likelihood สูงสุดคือประมาณ ... ช่วงความเชื่อมั่น 95% คือ ... ถึง ... ซึ่งครอบคลุมค่า *0* จึงใช้การแปลง *log* และทำการแปลงนี้ก่อน differencing

---

C. โจทย์ให้กราฟ ACF เพื่อถามเรื่อง stationary หรือค่า d



ผลการรัน R_codes ส่วน IMA(1,1): ข้อมูลเดิมและผลต่างครั้งที่ 1

ACF ของข้อมูลเดิมคือ 0.93, 0.90, 0.85, 0.80 และยังเป็น 0.54 ที่ lag 10 แท่งสูงต่อเนื่องและเตี้ยลงทีละน้อย นี่คือการลดลงช้า ข้อมูลไม่เป็น stationary ส่วน ACF ของผลต่างครั้งที่ 1 คือ -0.38 ที่ lag 1 แล้วเป็น 0.10 และ 0.01 ซึ่งอยู่ในเส้นประ ± 0.16 นี่คือการลดลงเร็ว ผลต่างครั้งที่ 1 เป็น stationary จึงได้ $d = 1$

ดูอะไร

นับว่าแท่ง ACF ใช้กี่ lag จึงเข้าไปอยู่ในเส้นประ

เกณฑ์ตัดสิน

เห็น	สรุป	D
ACF ข้อมูลเดิมเข้าเส้นประภายใน 2 ถึง 3 lag	stationary	0
ACF ข้อมูลเดิมสูงต่อเนื่องเกิน 10 lag แต่ ACF ของผลต่างครั้งที่ 1 เข้าเส้นประเร็ว	ต้อง differencing หนึ่งครั้ง	1
ACF ของผลต่างครั้งที่ 1 ยังสูงต่อเนื่อง แต่ ACF ของผลต่างครั้งที่ 2 เข้าเส้นประเร็ว	ต้อง differencing สองครั้ง	2
ACF ของผลต่างสูงซ้ำที่ lag 12, 24, 36 (หรือ 1.0, 2.0, 3.0 ถ้าแกนเป็นปี)	trend หมดแล้ว แต่ยังมี seasonality	ระบุว่า seasonal เหลืออยู่

เหตุผลของ $d = 1$ กับ $d = 2$: ทำครั้งเดียวพอเมื่อข้อมูลเปลี่ยนระดับด้วยอัตราคงที่ เช่น 10, 12, 14, 16 ได้ผลต่าง 2, 2, 2 ต้องทำสองครั้งเมื่ออัตราการเปลี่ยนเองก็เปลี่ยน เช่น 10, 12, 15, 19, 24 ได้ผลต่าง 2, 3, 4, 5 ซึ่งยังมี trend ทำอีกครั้งได้ 1, 1, 1

> **แม่แบบคำตอบ**
> ACF ของ *ข้อมูลเดิม* ลดลงช้ามาก โดยมีค่า ... ที่ lag 1 และยังเป็น ... ที่ lag ... ซึ่งเป็นสัญญาณของ nonstationarity จึงทำผลต่างครั้งที่ 1 ACF ของผลต่างครั้งที่ 1 ลดลงเร็ว โดยเข้าเส้นประตั้งแต่ lag ... จึงใช้ $d =$ *1* และหา p, q จาก ACF และ PACF ของผลต่างครั้งที่ 1

D. โจทย์ให้ผล Augmented Dickey-Fuller Test

```
Dickey–Fuller = –7.1518, Lag order = 5, p–value = 0.01
alternative hypothesis: stationary
```

ดูอะไร

ดู p-value ค่าเดียว ค่า Dickey-Fuller และ Lag order ไม่ใช้ตัดสิน

เกณฑ์ตัดสิน

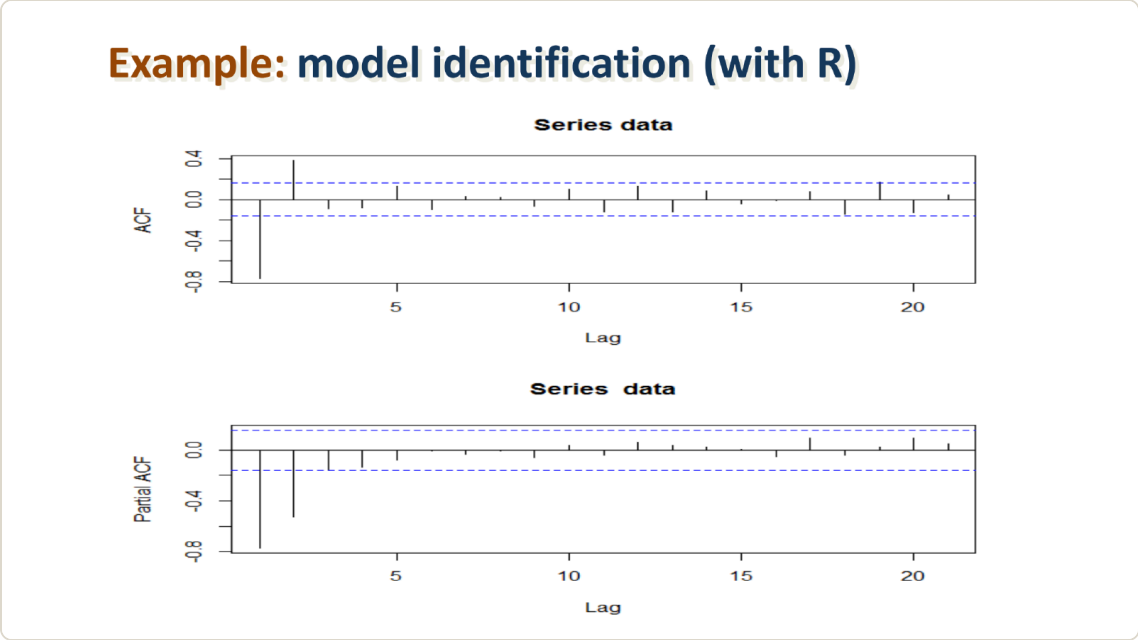
P-VALUE	สรุป	ทำต่อ
น้อยกว่า 0.05	ปฏิเสธ H_0 ข้อมูลเป็น stationary	ไม่ต้อง differencing เพิ่ม
ตั้งแต่ 0.05 ขึ้นไป	ไม่ปฏิเสธ H_0 ไม่มีหลักฐานว่า stationary	ทำ differencing แล้วทดสอบใหม่

H_0: ข้อมูลไม่เป็น stationary และ H_1: ข้อมูลเป็น stationary

แม่แบบคำตอบ

สมมติฐานหลักคือข้อมูลไม่เป็น stationary ค่า p-value = *0.01* ซึ่ง *น้อยกว่า* 0.05 จึง *ปฏิเสธ* สมมติฐานหลัก สรุปว่าข้อมูล *เป็น* stationary จึง *ไม่ต้องทำ differencing*

E. โจทย์ให้กราฟ ACF คู่กับ PACF เพื่อถามโมเดล



Slide 7 หน้า 22

ACF เกินเส้นประ ±0.163 ที่ lag 1 (−0.771) และ lag 2 (0.382) แล้วเข้าเส้นประตั้งแต่ lag 3 ส่วน PACF เกินเส้นประที่ lag 1 (−0.771) และ lag 2 (−0.524) แล้วเข้าเส้นประ รูปแบบนี้อ่านได้สามแบบ คือ MA(2) จาก ACF, AR(2) จาก PACF หรือ ARMA ถ้ามองว่าทั้งสองกราฟค่อย ๆ ลดลง จึงต้องใช้ AIC และ BIC ตัดสิน

ดูอะไร

1. ตรวจก่อนว่า ACF ลดลงเร็ว ถ้าลดลงช้าให้กลับไปหัวข้อ C
2. นับจำนวนแท่งที่เกินเส้นประใน ACF ก่อนจะเข้าเส้นประ
3. นับแบบเดียวกันใน PACF

4. ดูว่าแต่ละกราฟตัดทันที (cuts off) หรือค่อย ๆ ลดลง (tails off)

ถ้ากราฟ ACF เริ่มที่ lag 0 แท่งแรกจะสูงเท่ากับ 1 เสมอ ไม่ต้องนับ

เกณฑ์ตัดสิน

ACF	PACF	โมเดล
cuts off หลัง lag q	tails off	MA(q)
tails off	cuts off หลัง lag p	AR(p)
tails off	tails off	ARMA(p,q) ใช้ AIC/BIC หรือ EACF
ไม่มีแท่งเกินเส้นประ	ไม่มีแท่งเกินเส้นประ	white noise

ถ้ากราฟมาจากผลต่างครั้งที่ 1 ให้เติม d = 1 ในคำตอบ เช่น MA(1) ของผลต่างคือ ARIMA(0,1,1)

> **แม่แบบคำตอบ**
> ACF มีนัยสำคัญที่ lag ... แล้ว *ตัดทันที / ค่อย ๆ ลดลง* ส่วน PACF มีนัยสำคัญที่ lag ... แล้ว *ตัดทันที / ค่อย ๆ ลดลง* รูปแบบนี้ตรงกับ *MA(q) / AR(p) / ARMA* โมเดลที่เสนอคือ *ARIMA(p,d,q)*

F. โจทย์ให้ตาราง AIC และ BIC

```
> table1                                  > table2
         [,1]     [,2]     [,3]     [,4]           [,1]     [,2]     [,3]     [,4]
[1,] 699.6773 558.8091 518.3046 503.9312   [1,] 705.6985 567.8410 530.3471 518.9843
[2,] 563.2884 503.3127 502.2742 503.7573   [2,] 572.3203 515.3553 517.3273 521.8211
[3,] 513.2769 501.2778 502.3499 504.3320   [3,] 525.3195 516.3310 520.4137 525.4065
[4,] 508.8412 502.6837 504.3389 506.3401   [4,] 523.8944 520.7475 525.4133 530.4252
```

ดูอะไร

1. หาค่าต่ำสุดของแต่ละตาราง
2. อ่านเลขแถวและเลขคอลัมน์ แล้วลบ 1 จากทั้งคู่ แถวให้ p และคอลัมน์ให้ q
3. ดูช่องที่ค่าใกล้ค่าต่ำสุด

ตำแหน่ง	โมเดล
แถวที่ 1	MA ล้วน: [1,2] MA(1), [1,3] MA(2), [1,4] MA(3)
คอลัมน์ที่ 1	AR ล้วน: [2,1] AR(1), [3,1] AR(2), [4,1] AR(3)
[1,1]	white noise

[2,2], [3,2], [2,3]	ARMA(1,1), ARMA(2,1), ARMA(1,2)

เกณฑ์ตัดสิน

- ค่ายิ่งต่ำยิ่งดี ทั้ง AIC และ BIC
- ถ้าสองตารางเลือกต่างกัน ให้รายงานทั้งคู่ BIC มักเลือกโมเดลเล็กกว่า เพราะ penalty ต่อพารามิเตอร์คือ ln n ซึ่งมากกว่า 2 เมื่อ n ตั้งแต่ 8 ขึ้นไป
- ถ้าค่าต่างกันเล็กน้อย เลือกโมเดลที่มีพารามิเตอร์น้อยกว่า ตาม Principle of Parsimony

แม่แบบคำตอบ
AIC ต่ำสุดคือ ... ที่ช่อง [i , j] ซึ่งคือ ARMA($i-1$, $j-1$) BIC ต่ำสุดคือ ... ที่ช่อง [i , j] ซึ่งคือ ARMA(...)
โมเดลที่เลือกคือ ... เพราะ *มีค่าต่ำสุดทั้งสองเกณฑ์/ BIC ต่ำสุดและใช้พารามิเตอร์น้อยกว่า โดย AIC สูงกว่าค่าต่ำสุดเพียง ...*

> **ตัวอย่างคำตอบ:** AIC ต่ำสุดคือ 501.28 ที่ช่อง [3,2] ซึ่งคือ ARMA(2,1) BIC ต่ำสุดคือ 515.36 ที่ช่อง [2,2] ซึ่งคือ ARMA(1,1) สองเกณฑ์เลือกต่างกันเพราะ BIC ลงโทษจำนวนพารามิเตอร์หนักกว่า โมเดลที่เลือกคือ ARMA(1,1) เพราะ BIC ต่ำสุด ใช้พารามิเตอร์น้อยกว่าหนึ่งตัว และ AIC สูงกว่าค่าต่ำสุดเพียง 2.03

G. โจทย์ให้ผลที่มี Coefficients, s.e., sigma^2

```
arima(x = data, order = c(1, 0, 1), method = "ML")
Coefficients:
          ar1      ma1  intercept
      -0.6169  -0.7233     0.0235
s.e.   0.0686   0.0543     0.0179
sigma^2 estimated as 1.57:  log likelihood = -247.66,  aic = 503.31
```

G1. ถามว่าเป็นโมเดลอะไร

อ่านจาก `order = c(p, d, q)` ตัวอย่างนี้คือ p = 1, d = 0, q = 1 คือ ARIMA(1,0,1) หรือ ARMA(1,1) ถ้าบรรทัดแรกเป็น `arima(x = diff(data), order = c(2, 0, 0))` คำตอบคือ ARIMA(2,1,0) ของข้อมูลเดิม

G2. ถามให้เขียนสมการ

ค่าใน R	สัญลักษณ์	ตำแหน่งในสมการ
ar1, ar2	ϕ_1, ϕ_2	คูณกับ X_{t-1}, X_{t-2}
ma1, ma2	θ_1, θ_2	คูณกับ w_{t-1}, w_{t-2}
intercept	μ	ลบออกจาก X ทุกตัว

sigma ^ 2	σ_w^2	ความแปรปรวนของ w_t

โมเดล	รูปที่ใช้เขียน
AR(1)	$(X_t - \mu) = \phi(X_{t-1} - \mu) + w_t$
AR(2)	$(X_t - \mu) = \phi_1(X_{t-1} - \mu) + \phi_2(X_{t-2} - \mu) + w_t$
MA(1)	$X_t = \mu + w_t + \theta w_{t-1}$
MA(2)	$X_t = \mu + w_t + \theta_1 w_{t-1} + \theta_2 w_{t-2}$
ARMA(1,1)	$(X_t - \mu) = \phi(X_{t-1} - \mu) + w_t + \theta w_{t-1}$
ARIMA(0,1,1)	$X_t - X_{t-1} = w_t + \theta w_{t-1}$
ARIMA(1,1,1)	$\nabla X_t = \phi \nabla X_{t-1} + w_t + \theta w_{t-1}$ โดย $\nabla X_t = X_t - X_{t-1}$

แทนค่าโดยคงเครื่องหมายตามที่ R พิมพ์ ค่าลบให้เขียนเป็นลบ เมื่อ d ตั้งแต่ 1 ขึ้นไปจะไม่มี intercept

> **ตัวอย่างคำตอบ:** $(X_t - 0.0235) = -0.6169\,(X_{t-1} - 0.0235) + w_t - 0.7233\,w_{t-1}$ โดย w_t เป็น white noise ที่มีความแปรปรวน 1.57

G3. ถามว่าสัมประสิทธิ์ใดมีนัยสำคัญ

นำค่าประมาณหารด้วย s.e. ที่อยู่ใต้ค่านั้น ถ้าค่าสัมบูรณ์มากกว่า 2 ถือว่ามีนัยสำคัญที่ระดับ 0.05

> **แม่แบบคำตอบ**
> ค่า *ar1* ÷ s.e. = *−0.6169* ÷ *0.0686* = *−8.99* ค่าสัมบูรณ์ *มากกว่า* 2 จึง *มีนัยสำคัญ* ช่วงความเชื่อมั่น 95% คือ *−0.6169* ± 1.96 × *0.0686* ได้ *−0.751* ถึง *−0.482* ซึ่ง *ไม่ครอบคลุม* ศูนย์

> **ตัวอย่างคำตอบ:** ar1: −8.99 มีนัยสำคัญ ma1: −0.7233 ÷ 0.0543 = −13.32 มีนัยสำคัญ intercept: 0.0235 ÷ 0.0179 = 1.31 ไม่มีนัยสำคัญ ค่าเฉลี่ยของข้อมูลจึงไม่ต่างจากศูนย์

ถ้ามีพจน์ที่ไม่มีนัยสำคัญ ให้ตอบว่าควรตัดพจน์นั้นออกแล้ว fit โมเดลที่เล็กลง

G4. ถามให้หาค่าที่ขาด

ต้องการ	สูตร	ตัวอย่าง
AIC	−2 × log likelihood + 2k	−2(−247.66) + 2(4) = 503.32
BIC	−2 × log likelihood + k × ln n	495.32 + 4(5.011) = 515.36
BIC จาก AIC	AIC + k × (ln n − 2)	503.31 + 4(3.011) = 515.35
log likelihood จาก AIC	(2k − AIC) ÷ 2	(8 − 503.31) ÷ 2 = −247.66
s.e. จากผลหาร	ค่าประมาณ ÷ ผลหาร	−0.6169 ÷ −8.99 = 0.0686

ค่า k: R นับ p + q บวก 1 ถ้ามี intercept บวก 1 สำหรับ sigma ^ 2 ตัวอย่างนี้ได้ 4 ส่วนนิยามในสไลด์หน้า 18 ไม่นับความแปรปรวนของ white noise และให้ k = p + q เมื่อไม่มี intercept ถ้าโจทย์ให้ k มา ใช้ค่าที่โจทย์ให้ ถ้าไม่ให้ ระบุในคำตอบว่า

นับอย่างไร

ค่า ln n ที่ใช้บ่อย: ln 50 = 3.912, ln 100 = 4.605, ln 150 = 5.011, ln 200 = 5.298

G5. ถามให้เทียบสองโมเดล

> **แม่แบบคำตอบ**
> โมเดล _A_ มี aic = ... และโมเดล _B_ มี aic = ... โมเดล ... มี aic ต่ำกว่า และสัมประสิทธิ์ทุกตัว *มีนัยสำคัญ/...* จึงเลือกโมเดล ...

H. โจทย์ให้ค่า ACF หรือ autocovariance เพื่อประมาณด้วย Yule-Walker

ดูอะไร

ดูว่าโจทย์ให้ $\hat{\rho}$ (ค่า ACF) หรือ $\hat{\gamma}$ (autocovariance) ถ้าให้ $\hat{\gamma}$ ให้หารด้วย $\hat{\gamma}(0)$ ก่อน: $\hat{\rho}(h) = \hat{\gamma}(h)/\hat{\gamma}(0)$

โมเดล	สูตร
AR(1)	$\hat{\phi} = \hat{\rho}(1)$
AR(1) ความแปรปรวน	$\hat{\sigma}_W^2 = \hat{\gamma}(0)\,(1 - \hat{\phi}^2)$
AR(2)	$\hat{\phi}_2 = \dfrac{\hat{\rho}(2) - \hat{\rho}(1)^2}{1 - \hat{\rho}(1)^2}$ และ $\hat{\phi}_1 = \dfrac{\hat{\rho}(1)\,(1 - \hat{\rho}(2))}{1 - \hat{\rho}(1)^2}$
AR(2) ความแปรปรวน	$\hat{\sigma}_W^2 = \hat{\gamma}(0)\,[1 - \hat{\phi}_1\hat{\rho}(1) - \hat{\phi}_2\hat{\rho}(2)]$

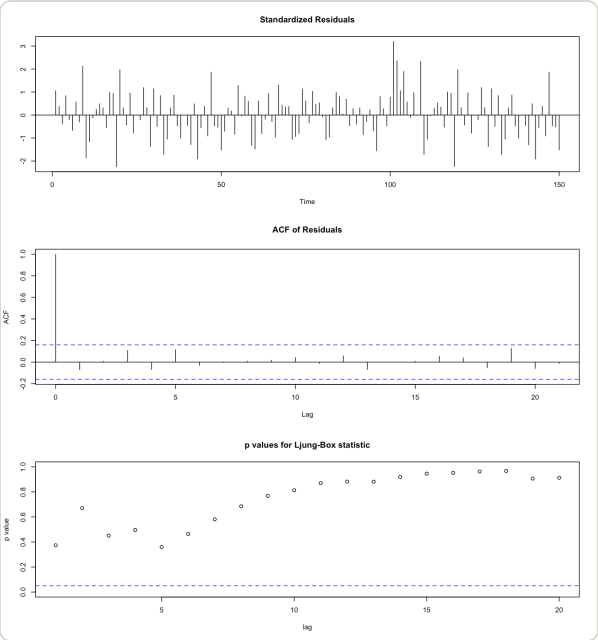
ที่มาของสูตร: คูณสมการ AR ด้วย X_{t-h} แล้วหาค่าคาดหมาย ได้ $\gamma(h) = \phi_1\gamma(h-1) + \cdots + \phi_p\gamma(h-p)$ จากนั้นแทน γ ด้วยค่าจากตัวอย่าง

> **ตัวอย่างคำตอบ:** ให้ $\hat{\rho}(1) = -0.771$, $\hat{\rho}(2) = 0.382$, $\hat{\gamma}(0) = 6.05$ AR(1): $\hat{\phi} = -0.771$ และ $\hat{\sigma}_W^2 = 6.05(1 - 0.594) = 2.45$ AR(2): $\hat{\phi}_2 = (0.382 - 0.594)/0.406 = -0.524$ และ $\hat{\phi}_1 = (-0.771)(0.618)/0.406 = -1.175$

ตรวจคำตอบ AR(2) ได้โดยแทนกลับ: $\hat{\phi}_1 + \hat{\phi}_2\hat{\rho}(1)$ ต้องเท่ากับ $\hat{\rho}(1)$ ในที่นี้ $-1.175 + (-0.524)(-0.771) = -0.771$

ข้อเท็จจริงที่ใช้ตอบต่อ: PACF ที่ lag 1 เท่ากับ $\hat{\rho}(1)$ และ PACF ที่ lag 2 เท่ากับ $\hat{\phi}_2$ ของ AR(2)

I. โจทย์ให้ผลการตรวจ residual



ผล tsdiag ของ ARMA(1,1) กับ times.txt

Standardized residuals อยู่ระหว่าง −2.24 ถึง 3.20 และแกว่งรอบศูนย์โดยไม่มีรูปแบบ ACF ของ residual ที่ lag 1 ถึง 6 มีค่าสูงสุด 0.116 ซึ่งอยู่ในเส้นประ ±0.163 ทุกแท่ง ค่า p-value ของ Ljung-Box ต่ำสุดคือ 0.36 และทุกค่ามากกว่า 0.05 residual จึงมีลักษณะเหมือน white noise โมเดลผ่านการตรวจสอบ

ดูอะไรและเกณฑ์ตัดสิน

ผลที่ให้มา	ผ่านเมื่อ	ถ้าไม่ผ่าน หมายความว่า
กราฟ Standardized Residuals	แกว่งรอบศูนย์ ไม่มีรูปแบบ ส่วนใหญ่อยู่ระหว่าง −2 ถึง 2	ยังมีรูปแบบเหลือ หรือความแปรปรวนไม่คงที่หรือมี outliers
กราฟ ACF of Residuals	ทุกแท่งตั้งแต่ lag 1 อยู่ในเส้นประ	residual ยังสัมพันธ์กัน โมเดลเล็กไป
p values for Ljung-Box statistic	ทุกจุดอยู่เหนือเส้นประ 0.05	residual ยังมี autocorrelation โมเดลเล็กไป
Histogram	รูประฆัง สมมาตรรอบศูนย์	residual ไม่เป็นปกติ
Normal Q-Q Plot	จุดเรียงใกล้เส้นตรง	residual ไม่เป็นปกติ
Shapiro-Wilk	p-value มากกว่า 0.05	residual ไม่เป็นปกติ

H_0 ของ Shapiro-Wilk: residual มีการแจกแจงปกติ และ H_0 ของ Ljung-Box: residual ไม่มี autocorrelation ทั้งสองการทดสอบต้องการ p-value ที่สูง

แม่แบบคำตอบ

ACF ของ residual *อยู่ในเส้นประทุก lag / เกินเส้นประที่ lag ...* และ p-value ของ Ljung-Box *มากกว่า 0.05 ทุก lag / น้อยกว่า 0.05 ที่ lag ...* residual จึง *ไม่มี / ยังมี* autocorrelation การทดสอบ Shapiro-Wilk ให้ p-value = *...* ซึ่ง *มากกว่า* 0.05 จึง *ไม่ปฏิเสธ* ว่า residual มีการแจกแจงปกติ สรุปว่า residual *มีลักษณะเหมือน white noise โมเดลใช้ได้ / ยังไม่เป็น white noise โมเดลยังไม่เพียงพอ*

J. โจทย์ถามว่าโมเดลนี้ดีหรือไม่ และถ้าไม่ดีต้องทำอย่างไร

"โมเดลดี" หมายถึงโมเดลอธิบายรูปแบบในข้อมูลได้หมด ส่วนที่เหลือคือ residual เป็น white noise ตรวจ 4 ข้อ

ตรวจ	ผ่านเมื่อ	ถ้าไม่ผ่าน ให้ตอบว่า
1. residual ไม่มี autocorrelation (หัวข้อ I)	Ljung-Box p-value มากกว่า 0.05 และ ACF ของ residual อยู่ในเส้นประ	โมเดลเล็กไป เพิ่ม p หรือ q แล้วตรวจใหม่ ถ้า ACF ของ residual ลดลงช้า ให้เพิ่ม d
2. residual เป็นปกติ (หัวข้อ I)	Shapiro p-value มากกว่า 0.05, QQ plot ใกล้เส้นตรง	ตรวจ outliers และพิจารณาแปลงข้อมูล
3. สัมประสิทธิ์มีนัยสำคัญ (หัวข้อ G3)	ค่าประมาณ ÷ s.e. มีค่าสัมบูรณ์มากกว่า 2	โมเดลใหญ่ไป ตัดพจน์ที่ไม่มีนัยสำคัญออก
4. AIC/BIC ต่ำ (หัวข้อ F)	ต่ำสุดหรือใกล้ต่ำสุด	เปลี่ยนไปใช้โมเดลที่ค่าต่ำกว่า

ข้อ 1 สำคัญที่สุด โมเดลที่ไม่ผ่านข้อ 1 ถือว่ายังอธิบายข้อมูลไม่ครบ หลังแก้ทุกครั้งต้อง fit ใหม่และตรวจซ้ำ

แม่แบบคำตอบ

โมเดล *ARIMA(p,d,q) เหมาะสม / ยังไม่เหมาะสม* เพราะ (1) residual *ไม่มี / มี* autocorrelation: Ljung-Box p-value *...* (2) residual *เป็น / ไม่เป็น* ปกติ: Shapiro p-value = *...* (3) สัมประสิทธิ์ *ทุกตัวมีนัยสำคัญ / ... ไม่มีนัยสำคัญ* (4) AIC = *...* ซึ่ง *ต่ำสุด / ใกล้ต่ำสุด* ขั้นต่อไปคือ *ใช้โมเดลนี้พยากรณ์ / เพิ่ม q เป็น ... แล้วตรวจใหม่*

> **ตัวอย่างคำตอบ:** โมเดลที่ดี: ARMA(1,1) ของ times.txt เหมาะสม เพราะ Ljung-Box p-value อยู่ระหว่าง 0.36 ถึง 0.97 ทุก lag, Shapiro p-value = 0.307, ar1 และ ma1 มีผลหาร −8.99 และ −13.32, BIC ต่ำสุดในตาราง

> **ตัวอย่างคำตอบ:** โมเดลที่ไม่ดี: MA(1) ของ times.txt ยังไม่เหมาะสม เพราะ ACF ของ residual เป็น −0.486 ที่ lag 1 และ 0.337 ที่ lag 2 เกินเส้นประ ±0.163 และ Ljung-Box ที่ lag 10 ให้ p-value = 2.6e-09 น้อยกว่า 0.05 residual ยังมี autocorrelation จึงควรเพิ่มส่วน AR เป็น ARMA(1,1) แล้วตรวจใหม่

K. โจทย์เรื่อง ARIMA กับ exponential smoothing

ให้มา	หา	สูตร
θ ของ ARIMA(0,1,1)	α	$\alpha = 1 + \theta$

α	θ	$\theta = \alpha - 1$
θ, X_t, $\hat{X}_t$	$\hat{X}_{t+1}$	$(1+\theta)X_t - \theta\hat{X}_t$
α, X_t, $\hat{X}_t$	$\hat{X}_{t+1}$	$\alpha X_t + (1-\alpha)\hat{X}_t$

> **ตัวอย่างคำตอบ:** $\theta = -0.7$ ได้ $\alpha = 0.3$ ถ้า $X_t = 60$ และ $\hat{X}_t = 50$ ได้ $\hat{X}_{t+1} = 0.3(60) + 0.7(50) = 53$

วิธี SMOOTHING	ใช้เมื่อ	เทียบเท่า
Simple exponential smoothing	ไม่มี trend ไม่มี seasonality	ARIMA(0,1,1)
Double exponential smoothing	มี trend ไม่มี seasonality	ARIMA(0,2,2) ไม่มีค่าคงที่

ถ้าให้พิสูจน์

1. โมเดล: $X_t - X_{t-1} = w_t + \theta w_{t-1}$ จึงได้ $X_t = X_{t-1} + w_t + \theta w_{t-1}$
2. ที่เวลา t + 1: $X_{t+1} = X_t + w_{t+1} + \theta w_t$
3. เนื่องจาก $w_{t+1} = X_{t+1} - \hat{X}_{t+1}$ แทนลงไปได้ $\hat{X}_{t+1} = X_t + \theta w_t$
4. เนื่องจาก $w_t = X_t - \hat{X}_t$ ได้ $\hat{X}_{t+1} = X_t + \theta(X_t - \hat{X}_t) = (1+\theta)X_t - \theta\hat{X}_t$
5. ให้ $\alpha = 1 + \theta$ จึงได้ $-\theta = 1 - \alpha$ และ $\hat{X}_{t+1} = \alpha X_t + (1-\alpha)\hat{X}_t$

L. คำถามให้อธิบาย

คำถาม	คำตอบ
ขั้นตอนเลือกโมเดล ARIMA มีอะไรบ้าง	Step 1: plot ข้อมูลและหาการแปลงที่เหมาะสมถ้าจำเป็น Step 2: ดู sample ACF และ PACF เพื่อยืนยันว่าต้อง differencing หรือไม่ Step 3: ดู sample ACF, PACF, EACF ของข้อมูลที่แปลงและ differencing แล้ว เพื่อหา p และ q โดยใช้ AIC และ BIC ช่วย จากนั้นทำ parameter estimation และ model diagnostics
ทำไมต้องแปลงก่อน differencing	การแปลงแก้ความแปรปรวนไม่คงที่ และสไลด์กำหนดเป็น first step ส่วน differencing แก้ trend นอกจากนี้ log ใช้กับค่าบวกเท่านั้น แต่ผลต่างมีค่าลบได้
ทำไม ACF ที่ลดลงช้าแสดงว่าไม่ stationary	ข้อมูลที่มี trend มีค่าที่อยู่ใกล้กันในระดับเดียวกัน สไลด์ใช้คำว่า “hang together” ความสัมพันธ์จึงยังสูงแม้ห่างกันหลาย lag
ทำไมไม่ differencing เผื่อไว้	Overdifferencing ทำให้เกิดปัญหา model identifiability และแทบไม่จำเป็นต้องใช้ d มากกว่า 2
AIC และ BIC ต่างกันอย่างไร	AIC = $-2 \ln L + 2k$ และ BIC = $-2 \ln L + k \ln n$ พจน์แรกเหมือนกัน BIC มี penalty ต่อพารามิเตอร์มากกว่า จึงมักเลือกโมเดลเล็กกว่า ทั้งสองยิ่งต่ำยิ่งดี และสมมติ normality
พจน์ 2k มีไว้ทำอะไร	เป็น penalty ไม่ให้โมเดลมีพารามิเตอร์มากเกินไป ตาม Principle of Parsimony

Method of moments คืออะไร	การตั้ง sample moments ให้เท่ากับ population moments แล้วแก้สมการหาพารามิเตอร์ สำหรับ AR(p) คือเลือก φ ที่ทำให้ $\gamma(h) = \hat{\gamma}(h)$ สำหรับ $h = 0$ ถึง p ซึ่งได้สมการ Yule-Walker
MOM กับ MLE ต่างกันอย่างไร	MOM คำนวณง่าย แต่ not efficient สำหรับ ARMA(p,q) ส่วน MLE efficient คือความแปรปรวนต่ำ แต่เป็น difficult optimization problem และต้องเลือกจุดเริ่มต้นที่ดี
ข้อดีของ MLE	Efficient (low variance estimates) สมมติฐาน Gaussian มักสมเหตุสมผล และแม้ข้อมูลไม่ใช่ Gaussian การแจกแจงเชิงเส้นกำกับของค่าประมาณก็เหมือนกรณี Gaussian
ข้อเสียของ MLE	Difficult optimization problem และ need to choose a good starting point ซึ่งมักใช้ตัวประมาณอื่น
ทำไม likelihood ของ time series เขียนยาก	ข้อมูลแต่ละค่าไม่อิสระต่อกัน ต้องใช้ความหนาแน่นร่วมของทั้งเวกเตอร์ซึ่งมีเมทริกซ์ Γ_n สไลด์ระบุว่า exact likelihoods are difficult to write down and optimize
Yule-Walker ใช้กับโมเดลใด	AR(p) ใช้ Durbin-Levinson algorithm, MA(q) ใช้ Innovations algorithm โดยแทน γ ด้วย $\hat{\gamma}$ ส่วน ARMA(p,q) ใช้ได้แต่ not efficient
ได้โมเดลตัวเลือกหลายตัว ผิดหรือไม่	ไม่ผิด สไลด์หน้า 27 ระบุว่าน้อยครั้งที่จะได้โมเดลเดียวแบบ clear-cut มักได้โมเดลตัวเลือกจำนวนไม่มาก แล้วตัดสินด้วย estimation และ diagnostics
Box-Cox คืออะไร	การแปลงยกกำลัง $T(X_t) = (X_t^\lambda - 1)/\lambda$ เมื่อ $\lambda \neq 0$ และ $\ln X_t$ เมื่อ $\lambda = 0$ ใช้ทำให้ความแปรปรวนคงที่ ค่า λ เลือกจากข้อมูลด้วย likelihood

M. ตัวอย่างข้อสอบเต็ม พร้อมคำตอบ

โจทย์ให้ผลของ times.txt ทั้งหมด คือ กราฟข้อมูล ผล adf.test กราฟ ACF/PACF ตาราง AIC/BIC ผล arima และผลตรวจ residual แล้วถามว่าโมเดลใดเหมาะสม

คำตอบเรียงตามขั้น

1. **การแปลง**
   ข้อมูลแกว่งรอบศูนย์ระหว่างประมาณ -6 ถึง 6 ด้วยความกว้างคงที่ จึงไม่ต้องแปลง

2. **ค่า d**
   ACF ลดลงเร็ว โดยเข้าเส้นประตั้งแต่ lag 3 และ adf.test ให้ p-value $= 0.01$ น้อยกว่า 0.05 ข้อมูลเป็น stationary จึงใช้ $d = 0$

3. **ค่า p และ q**
   ACF มีนัยสำคัญที่ lag 1 และ 2 PACF มีนัยสำคัญที่ lag 1 และ 2 โมเดลตัวเลือกคือ MA(2), AR(2) และ ARMA ตาราง AIC ให้ 518.30, 513.28 และ 503.31 สำหรับ ARMA(1,1) AIC ต่ำสุดคือ ARMA(2,1) ที่ 501.28 และ BIC ต่ำสุดคือ ARMA(1,1) ที่ 515.36 เลือก ARMA(1,1) ตาม Principle of Parsimony

4. **ค่าประมาณ**
   $(X_t - 0.0235) = -0.6169(X_{t-1} - 0.0235) + w_t - 0.7233w_{t-1}$ โดย $\hat{\sigma}_w^2 = 1.57$ ar1 และ ma1 มีนัยสำคัญ (-8.99 และ -13.32) ส่วน intercept ไม่มีนัยสำคัญ (1.31)

5. **การตรวจสอบ**
   Ljung-Box ให้ p-value มากกว่า 0.05 ทุก lag และ Shapiro-Wilk ให้ p-value $= 0.307$ residual มีลักษณะเหมือน white noise

> สรุป: ARIMA(1,0,1) เหมาะสมกับข้อมูลชุดนี้

N. ตารางเปิดดูเร็ว

ทิศของ p-value

การทดสอบ	H_0	P-VALUE น้อยกว่า 0.05	P-VALUE ตั้งแต่ 0.05
Augmented Dickey-Fuller	ไม่ stationary	stationary ไม่ต้อง diff	ยังไม่ stationary ต้อง diff
Shapiro-Wilk	residual เป็นปกติ	ไม่เป็นปกติ	เป็นปกติ ผ่าน
Ljung-Box	residual ไม่มี autocorrelation	ยังมี autocorrelation โมเดลไม่พอ	ไม่มี ผ่าน

สัญลักษณ์

สัญลักษณ์	อ่านว่า	ความหมาย	ใน R
X_t	เอ็กซ์ ที	ค่าข้อมูลที่เวลา t	data

w_t	ดับเบิลยู ที	white noise ส่วนสุ่มที่พยากรณ์ไม่ได้	residuals
ϕ	ฟาย	สัมประสิทธิ์ AR	ar1, ar2
θ	ทีตา	สัมประสิทธิ์ MA	ma1, ma2
μ	มิว	ค่าเฉลี่ย	intercept
σ_w^2	ซิกมากำลังสอง	ความแปรปรวนของ white noise	sigma^2
p, d, q		อันดับ AR, จำนวนครั้ง differencing, อันดับ MA	order = c(p, d, q)
$\gamma(h)$	แกมมา	autocovariance ที่ lag h และ $\gamma(0)$ คือความแปรปรวน	
$\rho(h)$	โร	autocorrelation ที่ lag h เท่ากับ $\gamma(h)/\gamma(0)$	ความสูงของแท่ง ACF
หมวก เช่น $\hat{\phi}$	แฮต	ค่าที่ประมาณจากข้อมูล	
∇X_t	นาบลา	$X_t - X_{t-1}$	diff(data)
α	อัลฟา	น้ำหนักใน exponential smoothing	1 + ma1
λ	แลมบ์ดา	เลขชี้กำลังของ Box-Cox	
$\ln L$	ลอน แอล	log ของ likelihood ที่สูงสุด	log likelihood
k, n		จำนวนพารามิเตอร์, จำนวนข้อมูล	

ค่าที่ใช้บ่อย

N	50	100	150	200	400
เส้นประ $\pm 2/\sqrt{N}$	±0.283	±0.200	±0.163	±0.141	±0.100
LN N	3.912	4.605	5.011	5.298	5.991